# 电子科技大学 计算机科学与工程学院

# 标准实验报告

(实验)课程名称\_\_\_\_\_人工智能\_\_\_\_\_\_

# 电子科技大学

# 实 验 报 告

学生姓名: 朱若愚 学号: 2022150501027 指导教师: 段立新

实验地点: A2-413-1 实验时间: 2024.5.25


一、实验室名称: 计算机学院实验中心

二、实验项目名称: MDP 实验

三、实验学时: 5学时

#### 四、实验原理:

#### (1) 迷宫游戏说明



#### 图 1 迷宫游戏示例

如上图所示,本实验所研究的迷宫由一个二维表格构成。其中白色区域是可行走区域,黑色区域是陷阱区域,黄色区域是终点。规则如下:

- 1) 智能体从左下角出发,到达黄色区域即游戏成功。
- 2) 智能体每次可选择上、下、左、右四种移动动作,每次动作得到-1奖励。
- 3) 智能体不能移动出网络,如果下一步的动作命令会让智能体移动出边界, 那么这一步将不会执行,即智能体原地不动,得到-1奖励。
- 4) 智能体移动到黑色区域,得到-100奖励。
- 5) 智能体移动到黄色区域,该回合结束。

由图可知,最优的路线需要 13 步,因此最后智能体获得的奖励指在-13 左右为最佳结果。

#### (2) Q-Learning 算法

Q-Learning 是一种记录行为值(Q value)的方法,每种行为在一定的状态都会有一个值 Q(s,a),就是说行为 a 在 s 状态的值是 Q(s,a)。对于迷宫游戏,s 就是当前 agent 所在的地点了。每一步,智能体可以选择四种动作,所以动作 a 有四种

可能性。

在本实验里,已经提供了强化学习基本的训练接口,只需要实现 Q 表格的强化学习方法即可。算法框架如下:

```
Initialize Q(s,a) arbitrarily Repeat (for each episode):

Initialize s
Repeat (for each step of episode):

Choose a from s using policy derived from Q (e.g., \varepsilon-greedy)

Take action a, observe r, s'
Q(s,a) \leftarrow Q(s,a) + \alpha \big[ r + \gamma \max_{a'} Q(s',a') - Q(s,a) \big]
s \leftarrow s';
until s is terminal
```

#### 图 2 强化学习算法框架

可以看到,算法的核心部分是更新 Q 表格。训练目标是在评价阶段,智能体的平均奖励达到-13。做出可视化结果如下图。




图 3 Q-Learning 训练奖励曲线

#### 五、实验目的:

实验使用 Q 表格方法解决迷宫寻路问题,理解强化学习算法原理。

### 六、实验内容:

阅读代码,补全代码中缺失的部分,完成迷宫实验。

#### 七、实验器材(设备、元器件):

PC 微机一台

### 八、实验步骤:

1. choose\_action 函数:

使用贪心策略,首先计算  $\epsilon$  值,在前期鼓励探索,在后期倾向于记忆。 之后生成一个随机数,若该随机数大于  $\epsilon$  则选择 Q 值较大的行为,否则 随机。

2. predict 函数:

```
def predict(self, state):
    Q_list = self.Q_table(state, :)
    Q_max = pp.max(self.Q_table(state, :))
    action_list = np.where(Q_list == Q_max)[0]
    action = np.random.choice(action_list)
    return action
```

首先获取了给定状态下所有动作的 Q 值并找到最大值, 然后找出了所有 Q 值等于最大 Q 值的动作并从中随机选择一个动作。

3. update 函数:

```
def update(self, state, action, reward, next_state, done):

Q predict = self.Q table[state, action]
if done:

Q target = reward
Q target = reward else:

Q target = reward + self.gamma * np.max(self.Q table[next_state, :])
self.Q table[state, action] += self.lr * (Q target - Q predict)
```


根据是否完成计算 Q 值。如果完成,Q 值就是当前的奖励,否则以当前的奖励与下一个状态的最大 Q 值之和乘以衰减系数。最后根据学习率和目标 Q 值与预测 Q 值的差距,更新 Q 表。


4. 增多了 self.train\_eps 的值,训练数目翻倍,并且由于笔者电脑显卡具有 cuda 核心,取消了对


self.device = torch.device(


"cuda" if torch.cuda.is\_available() else "cpu") # check gpu 两行代码的屏蔽。

### 九、实验数据及结果分析:









## 十、实验结论:

Q-Learning 算法经过学习之后可以接近最优路径,使 rewards 为-13.

### 十一、总结及心得体会:

Q-Learning 算法相对简单、学习快速,不需要理解环境效率较高。但是比较莽撞,缺乏长期记忆力。

## 十二、对本实验过程及方法、手段的改进建议:

尝试其他的强化学习算法:例如 Sarsa、DQN 等;并对 Q-learning 和 Sarsa 方法进行对比分析。

报告评分:

指导教师签字: