电子科技大学<u>计算机科学与工程</u> 学院

标准实验报告

(实验)课程名称_数据挖掘与大数据分析__

电子科技大学教务处制表

电子科技大学 实验报告

学生姓名: 朱若愚 学号: 2022150501027 指导教师: 邵俊明

实验地点: 主楼 A2-413 实验时间: 2024.3.10

- 一、实验室名称: 主楼 A2-413
- 二、实验项目名称:
- (一) 认识数据与数据预处理
- (二) 关联规则挖掘
- (三) 分类算法
- 三、实验学时: 16
- 四、实验原理:

(−)

1、数据属性最小最大归一化(可尝试其它方法:如 ZSCORE)

 $v' = \frac{v - min_A}{max_A - min_A} (new _ max_A - new _ min_A) + new _ min_A$

其中v是属性A的某个观测值, minA和 maxA分别是属性A的最小值和最大值

上述公式将 A 属性的取值映射到区间[new_minA,new_maxA]

如果令 $new_maxA = 1$, $new_minA = 0$, 则将 A 属性映射到区间[0,1],

实现了数据归一化。

2、缺失值处理

对于数据中属性的缺失值,使用该属性的平均值来填补缺失值。

3、特征筛选

信息增益是用来进行特征筛选的常用算法,基本思想是选择那些特征对分类变量 Y 信息增益大,删除那些对分类无用的特征。

信息熵:
$$H(X) = -\sum_{i=1}^{n} p(x_i) \log p(x_i)$$
.
条件信息熵: $H(Y|X) \equiv \sum_{x \in \mathcal{X}} p(x) H(Y|X = x)$
 $= -\sum_{x \in \mathcal{X}} p(x) \sum_{y \in \mathcal{Y}} p(y|x) \log p(y|x)$

信息增益: IG(Y|X) = H(Y) – H(Y|X)
(二)

1、频繁项集产生(Frequent Itemset Generation)

其目标是发现满足最小支持度阈值的所有项集,这些项集称作频繁项 集。

2、规则的产生(Rule Generation)

其目标是从上一步发现的频繁项集中提取所有高置信度的规则,这些规则称作强规则(strong rule)。

 $(\overline{-})$

1、KNN 算法原理

KNN 属于 lazy learning,不会对训练样本数据进行学习,其做法是:

对于一个新数据, 计算它与训练集中数据的距离, 选择最短的 k 个作为邻居, 然后预测它的类别和 k 个邻居中其所属类别最多的一致。算法伪代码如下:

- (1) 读入并保存训练数据
- (2) 预测时, 计算已知类别数据集中的点与当前点之间的距离
- (3) 选取与当前距离最小的 k 个点
- (4) 计算前 k 个点所在类别的出现频率
- (5) 返回前 k 个点出现频率最高的类别作为当前点的预测分类

2、决策树算法原理

决策树是一种类似流程图的树结构,决策树中每个内部结点(非叶结点)表示在一个属性上的测试,每个分支代表该测试的一个输出,每个叶子结点代表类标签。给定类标号未知元组 X,在决策树上测试 X 的属性值,跟踪一条由根到叶结点的路径,该叶结点就存放着该元组的类预测。

决策树的构造

核心思想在于决策树越向下生长, 使节点的纯度越大。

自顶向下的分治方式构造决策树

递归的通过选择相应的测试属性,通过选择最有分类能力的属性作为 决策树的当前结点,由此划分样本,其中测试属性是根据某种启发信 息或者是统计信息来进行选择,如信息增益

决策树伪代码:

输入: 训练集 D

属性集A

过程: 函数 createTree(D,A)

1: 生成结点 node

2: If D 中样本全属于同一类别 C then

3: 将 node 标记为 C 类叶结点;return

4: end if

5: If A=空集 OR D 中样本在 A 上取值相同 then

6: 将 node 标记为叶结点,其类标记为 D 中样本数最多的类;return

7: end if

8: 从 A 中选择最优划分属性 a

9: for a 的每一个值 a* do

10: 为 node 生成一个分支;令 D*表示 D 中在 a 上取值为 a*的样本 子集;

11: if D*为空 then

12: 将分支结点标记为叶结点,其类标记为 D 中样本最多类

13: return;

14: else

15: 以 createTree(D*,A - {a})为分支结点

16: end if

17: end for

输出: 以 node 为根节点的一棵决策树

五、实验目的:

(-)

- 1、了解 Weka 工具包及 Eclipse 编程平台。
- 2、认识和了解数据。
- 3、对数据能进行简单的预处理。

(二)

- 1、掌握关联规则挖掘的基本概念、原理和一般方法
- 2、掌握 Apriori 算法
- 3、了解 FP-GROWTH 算法

 (\equiv)

- 1、了解分类的基本概念、原理和一般方法
- 2、掌握分类的基本算法
- 3、实现 KNN 或决策树算法

六、实验内容:

(-)

- 1、安装并配置 Java、Eclipse 和 Weka (已配置)。
- 2、使用图形界面的 Weka 工具包,完成数据归一化、缺失值处理、 特征筛选的数据预处理操作。
- 3、在 Eclipse 下调用 Weka.jar 包,完成数据归一化、缺失值处理、特征筛选的数据预处理操作。

(二)

1、学会调用 WEKA 包实现关联规则的挖掘

- 2、自己编程实现 Apriori 算法
- 七、实验器材(设备、元器件): 计算机
- 八、实验步骤:

(-)

- 1、配置实验环境
- 2.1、使用 Weka 图形界面工具完成数据归一化
 - (1) 打开 Weka GUI 工具
 - (2) 选择 Explorer
 - (3) 点击 Open file
 - (4) 选择数据文件 iris.arff
 - (5) 在 Filter 栏目下,选择 Choose
 - (6) 选择 weka->filters->unsupervised->attribute->Normalize
- (7) 点击"Normalize S 1.0 T 0.0"所在区域可以调整参数,由于本例选择将数据归一化到[0,1],使用默认的参数即可实现,点击Apply 将数据归一化
 - (8) 查看数据各个属性的值,已经归一化到[0,1]
- 2.2、使用 Weka 图形界面工具完成数据缺失值处理

数据使用 labor.arff, filter 使用 ReplaceMissingValues,参数默认

2.3、使用 Weka 图形界面工具完成特征筛选

数据使用 iris.arff, filter 使用 AttributeSelection, 其中参数 evaluator 选择 InfoGainAttributeEval, search 使用 Ranker, 需要调节 Ranker 的 参数,选择最大特征数目(需小于原始的特征数目)

- 3.1、在 Eclipse 下调用 Weka.jar 包完成数据归一化
 - (1) 首先,新建一个 Java 工程
 - (2) 接下来,导入 weka.jar
 - (3) 创建一个 package 包

New -> package -> 输入 cn.uestc.preprocessing

(4) 创建 Java 文件

在包下面创建一个新的 class: TestNormalize.java

New -> Class -> 输入 TestNormalize

- (5) 编辑 TestNormalize.java 文件, 导入包
- (6) 在 main 函数中完成数据归一化
- (7) 观察数据是否已经归一化,打印实验结果
- 3.2、在 Eclipse 下调用 Weka.jar 包完成数据缺失值处理
- 3.3、在 Eclipse 下调用 Weka.jar 包完成特征筛选 (二)
- 1、寻找合适的数据集并进行适当处理
- 2、根据实验原理,编写 Apriori 算法。
 - (1) 读取数据
- (2) 首先获取频繁一项集合(注意对于数据结构的选取提高计算效率)
 - (3) 利用 K 项频繁集生成 K+1 频繁候选集: 自连接+剪枝
 - (4) 重新扫描数据集,确定 K+1 频繁候选集中真正频繁的项集

重复上面两步

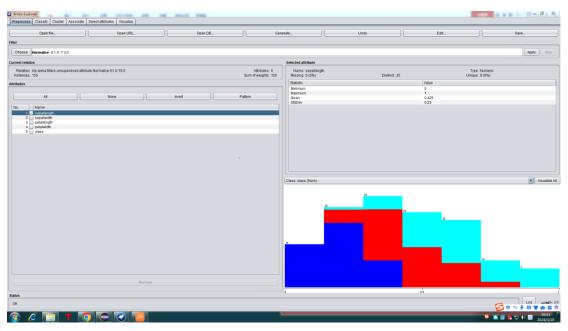
(三)

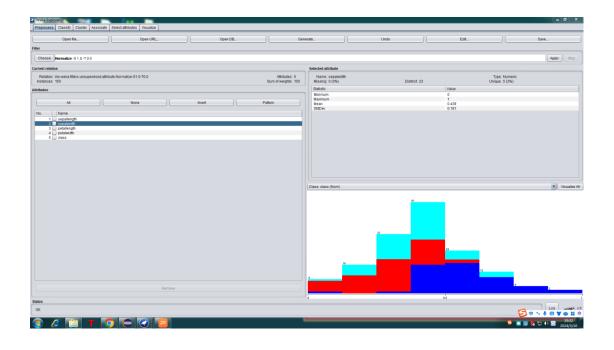
- 1、实现 KNN 算法
- 2、初步学习 MATLAB 实现 ANN 算法
- 3、实现决策树算法

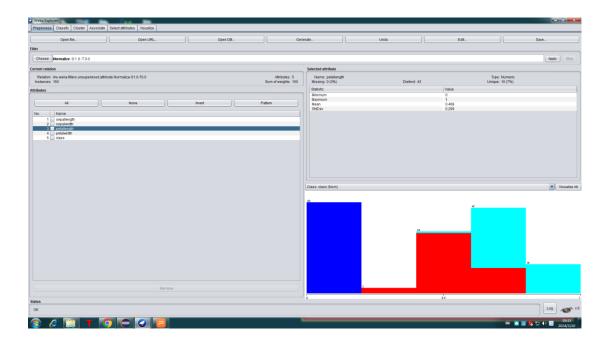
九、实验数据及结果分析:

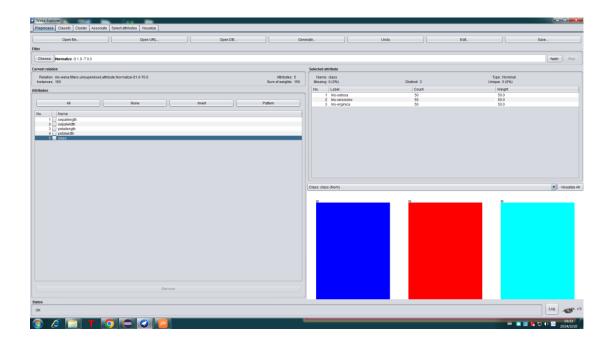
(一)

1.1 使用 Weka 图形界面工具完成数据归一化

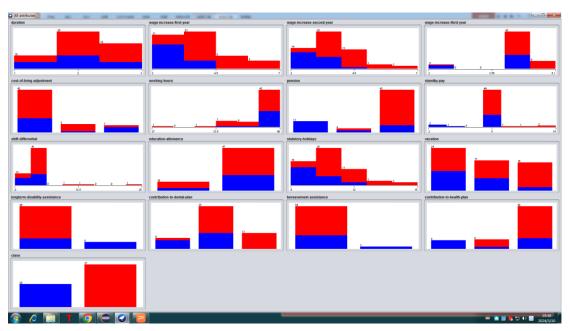




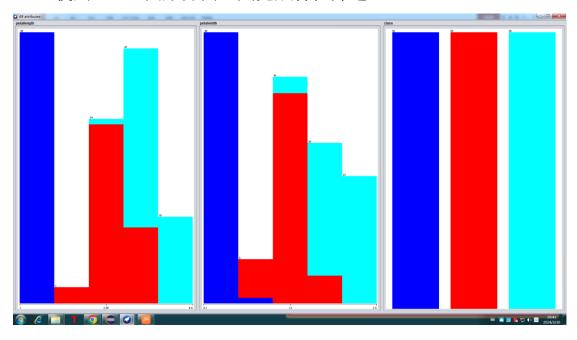




1.2、使用 Weka 图形界面工具完成数据缺失值处理

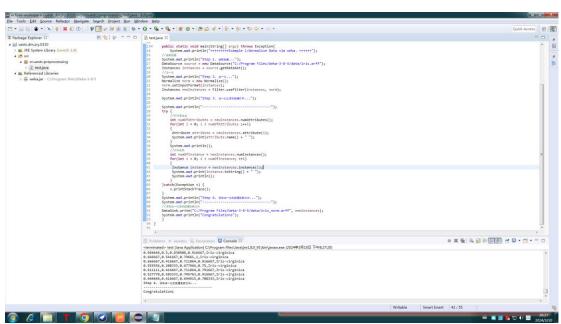


1.3、使用 Weka 图形界面工具完成特征筛选



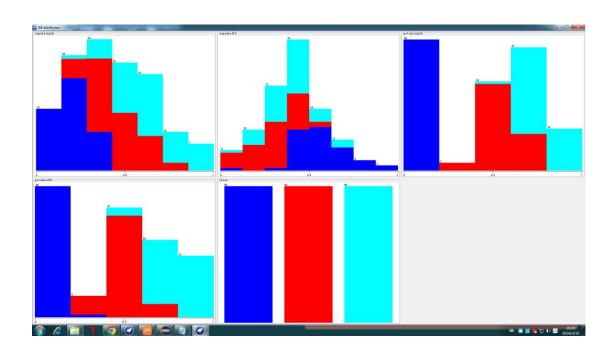
2.1、在 Eclipse 下调用 Weka.jar 包完成数据归一化

代码如下:



数据结果:

```
5 中 ·, ♦ □ ¥ ♠ $ ☆
5 □ 5 □ 10 □ 2029
2024/3/10
0. 19999, U, 0. 423729, U. 578, Iris-versicolor
```



2.2、在 Eclipse 下调用 Weka.jar 包完成数据缺失值处理

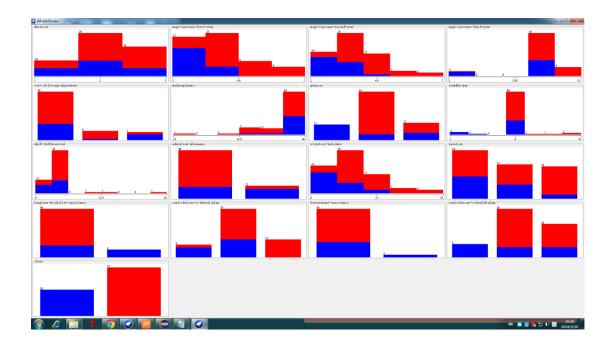
代码如下:

```
### Principal Control (1997)

| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Control (1997)
| Principal Contr
```

数据结果:

```
| Seed |
```



2.3、在 Eclipse 下调用 Weka.jar 包完成特征筛选

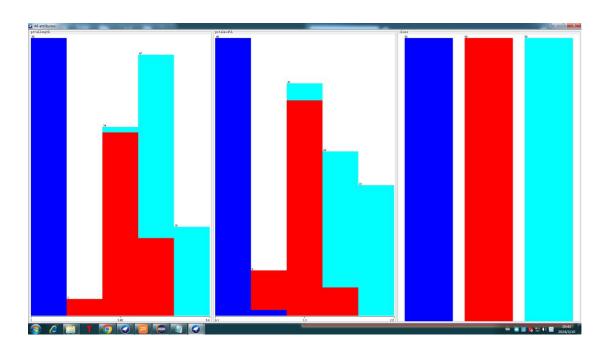
代码如下:

```
| Comparison of the continue of the continue projects from the projects from the continue projects fro
```

数据结果:

```
双班结果:

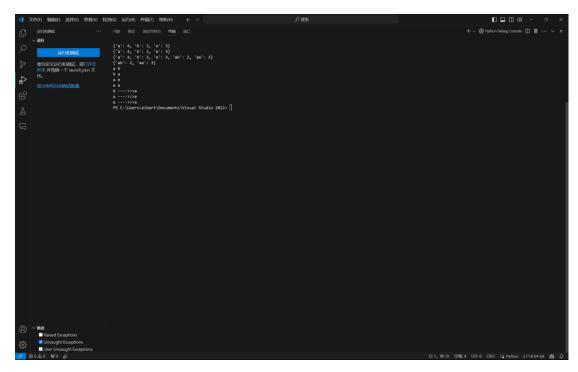
| Washington | See | S
           0. 0, 1, 1r15-vers1001or
```



(二)

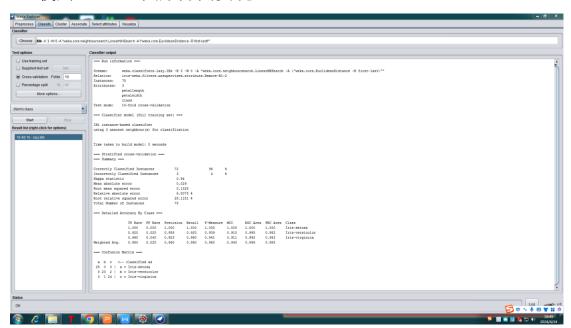
代码如下:

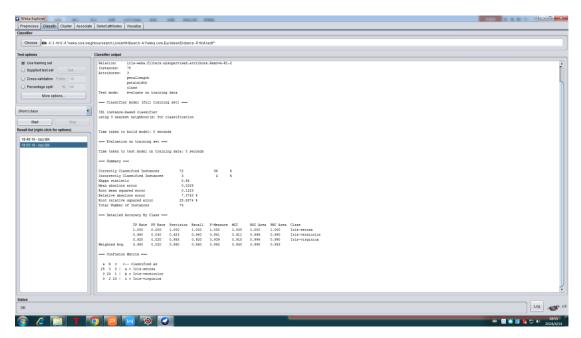
数据结果:



(三)

1、使用 WEKA 图形界面实现 KNN

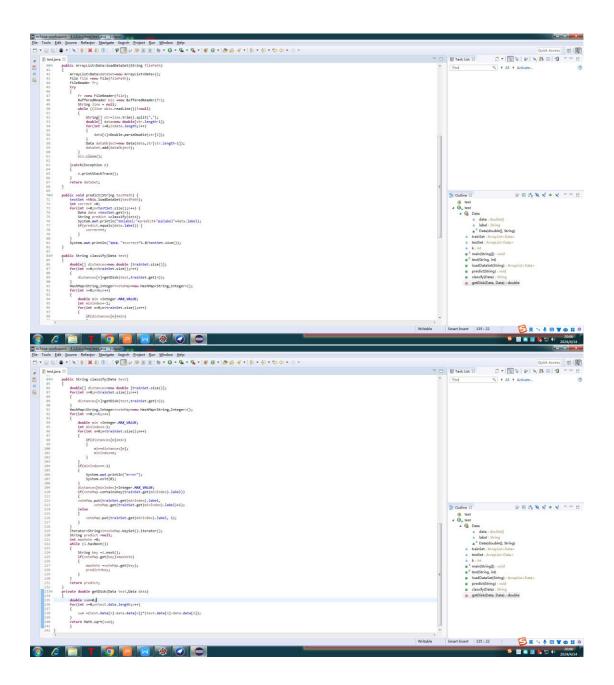




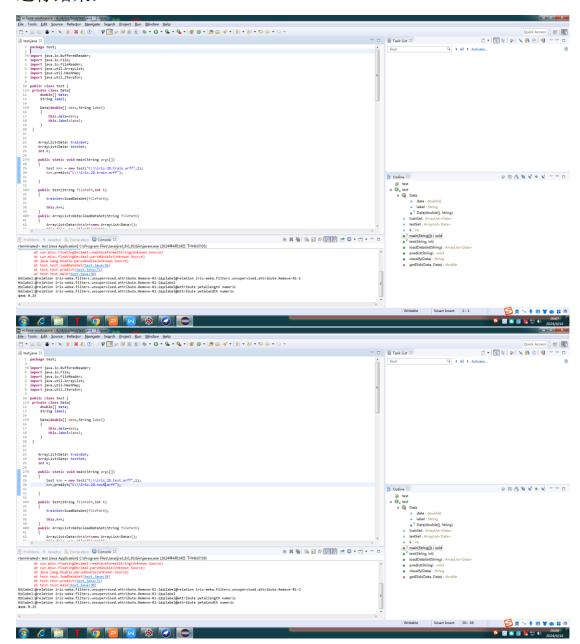
2、使用 JAVA 编写 KNN 算法

代码如下:

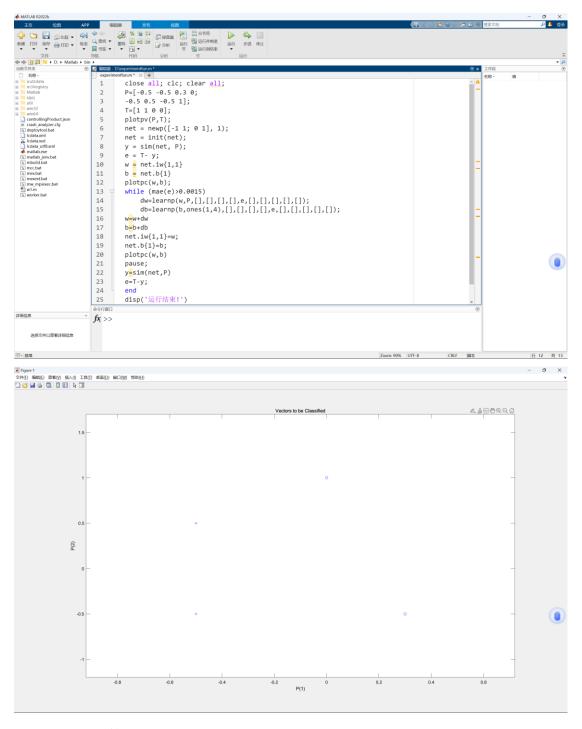
```
| International Content of the Conte
```



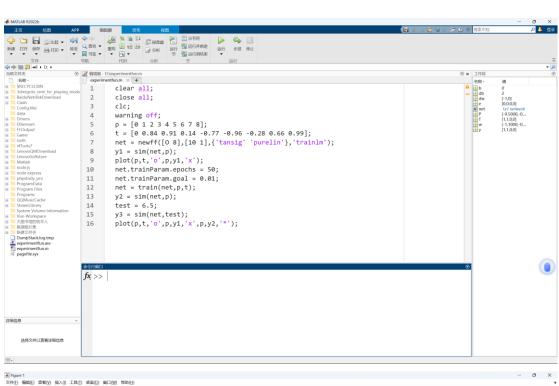
运行结果:

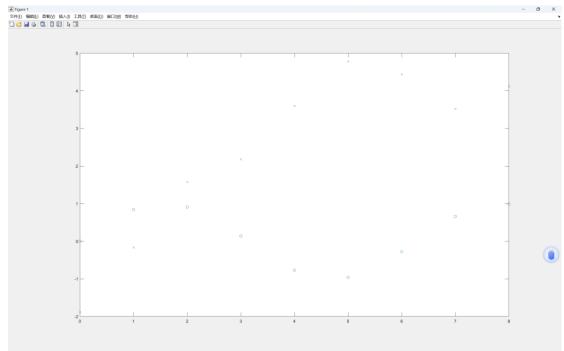


- 3、尝试利用 matlab 实现人工神经网络,包括感知机和后向传播网络(BP)
 - (1) 感知机



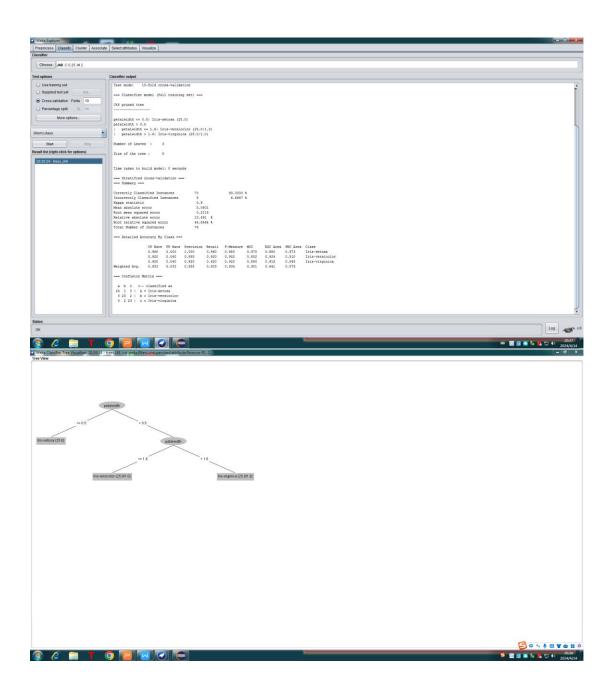
(2) BP 网络







4、使用 WEKA 图形界面实现决策树



十、实验结论:

(一)

使用 weka 和通过 Eclipse 调用 weka.jar 可以得到相同的数据处理结果。

(二)

Apriori 算法可以对离散数据进行频繁项集产生和规则产生

 (\equiv)

KNN 算法简单,快速,准确率较高,通过 weka 选择相应算法可以以 树的形式直观呈现出决策树。

十一、总结及心得体会:

(-)

通过使用 weka 以及调用 weka.jar 可以方便的对数据进行处理,得出归一化、缺失值处理、特征筛选的数据预处理结果。

(二)

使用 python 语言可以更快捷方便地对数据进行 Apriori 算法的频繁项 集产生和规则产生

 (\equiv)

由于 KNN 算法属于 lazy learning,不会对训练数据集做深入学习,而是单纯的考虑数据之间的距离,所以 KNN 的预测效果强依赖于训练数据。

十二、对本实验过程及方法、手段的改进建议:

(−)

尝试使用 C++语言对数据进行归一化、缺失值处理、特征筛选等操作。

(二)

用 Java 语言,同样可以实现 Apriori 算法,但是可能代码量更多。

 $(\underline{\Xi})$

使用更多训练数据后观察 KNN 算法的预测准确度变化。

报告评分:

指导教师签字: